

Распознавание исторических славянских текстов: от выбора движка до интеграции открытых моделей и датасетов

Анализ существующих открытых **OCR**-инструментов и специализированных моделей

В области оптического распознавания символов (OCR) и, в частности, распознавания рукописного текста (HTR), существует несколько ключевых открытых инструментов, которые могут быть адаптированы для работы с историческими славянскими текстами. Эти инструменты можно условно разделить на две категории: универсальные системы с возможностью дообучения и специализированные HTR-платформы. Ключевыми игроками в этом пространстве являются Tesseract, Kraken и Transkribus, каждый из которых обладает своими сильными и слабыми сторонами, особенно в контексте церковнославянского, древнеславянского и старорусского языков.

Tesseract OCR, разработанный Google, является одним из самых известных и широко используемых open-source OCR-движков ⁶⁵. Его архитектура LSTM (Long Short-Term Memory) позволяет ему работать с нелинейно расположенными символами, что делает его более подходящим для рукописных текстов по сравнению с более ранними версиями ⁶⁶. Однако стандартная установка Tesseract имеет серьезные ограничения при работе с историческими славянскими языками. По умолчанию он не содержит качественных моделей для распознавания церковнославянской орфографии, старославянских глифов или рукописного почерка ²⁴. Сообщество пользователей уже обращало внимание на этот пробел, предлагая добавлять недостающие символы вручную через систему отслеживания проблем, но это не решает фундаментальной проблемы отсутствия обученных моделей ³. Тем не менее, главным преимуществом Tesseract является возможность дообучения. Этот процесс позволяет создавать новые, специализированные модели, например, `rus_old`,

которая бы дополняла стандартный русскоязычный пакет, а не заменяла его. Такой подход предотвращает ошибочную расшифровку современных слов как старославянских ⁴⁶. Таким образом, Tesseract должен рассматриваться не как самостоятельное решение, а как базовый, дообучаемый движок, который может служить "резервной" системой или использоваться для печатных изданий, где качество распознавания обычно выше.

Другим мощным и гибким инструментом является Kraken. Эта система позиционируется как готовое к использованию решение для OCR, оптимизированное для исторического и неплатинского письма ⁷⁰. Важнейшей особенностью Kraken является полная обучаемость анализа компоновки страниц. Это означает, что модель не только распознает строки текста, но и сама учится находить их на изображении, что критически важно для документов со сложной структурой или плохого качества скана ⁷⁰. Kraken активно используется в академических проектах и часто упоминается в сравнительных анализах HTR-систем, что свидетельствует о его надежности и эффективности ^{17 94}. Он имеет активное сообщество и репозитории с предварительно обученными моделями, что значительно упрощает начало работы и интеграцию в другие приложения ⁷¹. Для задачи распознавания рукописных славянских текстов Kraken выглядит как один из наиболее перспективных кандидатов благодаря своей обучаемости и ориентации на исторические материалы.

Transkribus представляет собой не просто программный инструмент, а полноценную облачную платформу для HTR, которая стала отраслевым стандартом в цифровой гуманитаристике ¹⁶. Она предоставляет доступ к передовым моделям, таким как TrOCR, и интерфейс для их обучения и применения ⁸⁰. Platform предлагает широкий спектр готовых, обученных моделей, многие из которых являются открытыми и доступны для использования ^{20 22}. Например, существуют специализированные модели для распознавания церковнославянского языка в рукописях, таких как «Супрасльский кодекс» ⁴¹, и для старорусского каллиграфического почерка XVIII века ⁴⁴. Некоторые из этих моделей доступны в формате, совместимом с Kraken, например, через платформу eScriptorium ⁹⁴. Хотя Transkribus — это веб-сервис, его API и возможность использовать загружаемые модели делают его важным ресурсом. Приложение должно иметь функциональность для импорта и использования этих внешних моделей, что соответствует требованию пользователя о создании расширяемого решения.

Помимо классических OCR-движков, последнее время набирают популярность модели, основанные на архитектуре Transformer. Трансформеры показывают превосходство над предыдущими архитектурами, таким как CRNN, и открывают возможности для дальнейшего улучшения качества распознавания [35](#) [82](#) .

Одной из таких моделей является TrOCR, предложенная исследователями из Facebook AI, которая демонстрирует высокую производительность на задачах HTR [80](#) . Модели TrOCR и его производные активно используются в Transkribus, что делает их одними из самых мощных инструментов на сегодняшний день [67](#) .

Кроме того, существуют и другие специализированные модели, такие как LightOnOCR-2-1B-old-church-slavonic-line — это модель, специально дообученная для строкового OCR старославянского языка [21](#) , и trocr-handwritten-cyrillic — модель, обученная на церковнославянском, русском и украинском рукописях [45](#) . Интеграция этих новых, трансформерных моделей должна стать одной из главных целей проекта, поскольку они представляют собой наиболее перспективное направление для достижения высокого качества распознавания исторических текстов.

Инструмент/ Модель	Основное назначение	Поддержка славянских языков	Возможность дообучения	Лицензия
Tesseract OCR	Универсальный OCR, печатные и рукописные тексты	Ограниченная; требуется дообучение для старославянской орфографии 24	Да, основной способ адаптации 46	Apache 2.0 65
Kraken	Исторический и нелатинский OCR	Хорошая; есть предобученные модели и ориентирован на обучение 70 71	Да, полная обучаемость анализа компоновки 70	MIT 70
Transkribus (с TrOCR)	Продвинутая HTR-платформа	Отличная; много готовых моделей для церковнославянского и других языков 16 41	Да, через платформу или Kraken 94	Коммерческая (с открытыми моделями) 16
LightOnOCR-2-1B	Трансформерная модель для OCR	Есть специализированная модель для старославянского языка 21	Да, как базовая модель 21	Не указана
trocr-handwritten-cyrillic	Трансформерная модель для рукописного письма	Церковнославянский, русский, украинский 45	Да, как базовая модель 45	Не указана

Таким образом, для создания комплексного решения необходимо использовать комбинацию этих инструментов. Tesseract может служить базовым уровнем, Kraken — основным движком для рукописей, а модели из Transkribus — передовым уровнем для достижения максимальной точности.

Обзор научных публикаций и ключевых вызовов в области **HTR** для славянских языков

Научные исследования в области распознавания рукописного текста (HTR) предоставляют глубокое понимание проблем, методологий и потенциала технологий, предназначенных для работы с историческими документами, включая славянские языки. Анализ публикаций, представленных в источниках, позволяет выявить ключевые вызовы и направления развития, которые напрямую влияют на выбор и адаптацию OCR-инструментов.

Основной и наиболее часто упоминаемой проблемой является недостаток больших аннотированных корпусов — наборов данных, содержащих пары «изображение текста — эталонная транскрипция» [26](#) [93](#). Этот дефицит данных является фундаментальным препятствием для обучения высокоточных моделей машинного обучения, особенно для языков с ограниченным количеством сохранившихся рукописей. Без качественных аннотированных данных невозможно провести дообучение существующих моделей или создать новые с нуля. Это объясняет, почему большинство доступных моделей имеют ограниченную область применения и часто демонстрируют низкую производительность на текстах, не попавших в обучающую выборку.

Помимо общего дефицита данных, существуют и специфические для славянских языков вызовы. Во-первых, это значительное разнообразие и изменчивость шрифтов и почерков, особенно в рукописных источниках [5](#). Различия между кириллицей и глаголицей, а также между различными изводами одного и того же алфавита (например, *uncial*, *semi-uncial*) создают серьезные трудности для распознавания [2](#) [9](#). Во-вторых, исторические тексты часто содержат графические особенности, такие как лигатуры (соединение нескольких букв в один символ), аббревиатуры и диакритические знаки, которые современные OCR-системы могут интерпретировать неверно [72](#) [88](#). Например, некоторые модели для глаголицейского письма специально обучены распознавать и разбирать наиболее распространенные лигатуры и аббревиатуры [88](#). В-третьих, проблемы возникают из-за особенностей самого языка: отсутствие систематической пунктуации в древних текстах затрудняет автоматическое определение границ предложений, что усложняет как само распознавание, так и последующий анализ текста [18](#). Наконец, качество входных данных, то есть сканированных изображений, играет решающую роль. Артефакты, такие как шум, затухание чернил, неоднородное освещение и

низкий контраст, являются нормой для старых документов и могут значительно снизить точность любого OCR-движка [53](#) [70](#).

Методологическая эволюция в области HTR четко прослеживается в научных работах. Если ранее экспериментировались с более простыми подходами, например, на основе теории нечетких множеств для классификации букв [59](#), то сейчас доминирующим направлением стали глубокие нейронные сети. В частности, архитектуры на основе трансформеров, заимствованные из области обработки естественного языка, демонстрируют выдающиеся результаты [29](#) [82](#). Модели типа TrOCR, которые сочетают в себе преобразователь изображений и преобразователь текста, показывают лучшие результаты по сравнению с более ранними архитектурами, такими как CRNN (Convolutional Recurrent Neural Network) [35](#) [80](#). Переход к трансформерам не только повышает точность распознавания, но и открывает новые возможности, например, для применения больших языковых моделей (LLM) для постобработки и исправления ошибок, что является перспективным направлением исследований [11](#) [35](#).

Качество распознавания в научных публикациях обычно оценивается с помощью метрики CER (Character Error Rate), которая показывает процент ошибочно распознанных символов. Чем ниже значение CER, тем выше качество модели [60](#). Например, в одном из исследований было заявлено о достижении CER на уровне 3.29% для модели распознавания церковнославянской рукописи, что свидетельствует о высоком потенциале технологии при наличии правильных данных и настроек [60](#). Конференции, такие как LT4HALA (Workshop on Language Technologies for Historical and Ancient Languages), являются ключевыми площадками для публикации и обсуждения новейших достижений в этой области, и их сборники трудов содержат множество релевантных статей [1](#).

Таким образом, научный анализ подтверждает, что работа над OCR для исторических славянских текстов является сложной, но хорошо изученной исследовательской областью. Создание успешного приложения требует не только выбора правильного инструмента, но и глубокого понимания этих вызовов. Ключевыми факторами успеха становятся наличие мощного конвейера предобработки изображений, способного бороться с артефактами, и стратегия работы с данными, включающая сбор и использование аннотированных наборов для дообучения моделей.

Доступные открытые датасеты для обучения и дообучения моделей распознавания текста

Наличие высококачественных и аннотированных наборов данных является краеугольным камнем для обучения и тестирования любой системы распознавания текста, будь то OCR или HTR. Для исторических славянских языков, как и для многих других малоизученных языков, такой ресурс крайне ценен и относительно редок. Однако, несмотря на общее правило об их дефиците, в предоставленных источниках упоминается ряд конкретных и ценных наборов данных, которые могут быть использованы для дообучения существующих моделей и создания новых.

Одним из наиболее релевантных и специализированных наборов данных является `russian-old-orthography-ocr`. Этот датасет был специально создан для тренировки и оценки систем OCR для текстов, опубликованных на русском языке до орфографической реформы 1918 года ⁶⁹. Он представляет собой ценный ресурс для дообучения базовых движков, таких как Tesseract, чтобы они могли корректно распознавать историческую орфографию и нестандартные для современного русского языка глифы. Использование этого датасета позволяет значительно повысить точность распознавания в старых печатных изданиях и рукописях.

Для церковнославянского языка также существуют специализированные коллекции. Набор данных `Combined_Full_VKS_2` предназначен для распознавания текста на церковнославянском языке и включает в себя как изображения рукописей, так и соответствующие эталонные транскрипции ⁷. Этот набор данных является идеальным кандидатом для обучения и валидации моделей, нацеленных на работу с Библией или другими литургическими текстами. Проект «Супрасльский кодекс» также предоставляет доступ к своим цифровым изображениям и транскрипциям, что является бесценным ресурсом для исследователей данного уникального памятника ⁴¹.

Помимо специализированных наборов, существуют и более крупные мультязычные коллекции, которые могут содержать и славянские материалы. Например, набор данных `LIST` состоит из более чем 525 тысяч надписей на различных языках, обогащенных 65 атрибутами, и может содержать релевантные образцы ⁴⁷. Другой пример — Nuremberg Letterbooks, огромный набор данных, содержащий почти 51 тысячу страниц переписки с XVI века,

который также доступен для исследователей ⁵². Эти большие коллекции могут быть полезны для обучения более общих, «гибридных» моделей, способных работать с несколькими языками одновременно ⁸¹.

Для получения доступа к этим и другим данным исследователи и разработчики могут обратиться к нескольким ключевым платформам. Zenodo является открытым репозиторием научных данных, где часто публикуются результаты исследовательских проектов вместе с наборами данных ⁵². Ресурс CLARIN ERIC предоставляет доступ к широкому спектру цифровых языковых ресурсов, включая исторические тексты ⁷⁴. Также стоит отметить академические проекты и университетские центры, которые занимаются изучением средневековых славянских рукописей, например, Resource Center for Medieval Slavic Studies в The Ohio State University, которые могут предоставлять информацию о доступных цифровых коллекциях ³⁹.

Название датасета / Ресурс	Язык(и)	Содержание	Лицензия / Доступность
russian-old-orthography-ocr	Русский (до 1918 г.)	Изображения и транскрипции для дообучения OCR ⁶⁹	Datasets at GitHub (не указано)
Combined_Full_VKS_2	Церковнославянский	Изображения и транскрипции для распознавания текста на церковнославянском языке ⁷	Unknown
The Codex Suprasliensis Project	Церковнославянский	Цифровые изображения и параллельная транскрипция ⁴¹	Open Access
Church Slavic Text Recognition	Церковнославянский	Набор данных для распознавания текста на церковнославянском языке ⁷	Unknown
Handwritten Glagolitic	Хорватский (Глаголица)	Изображения рукописного глаголицейского текста и транскрипции ⁸⁸	Unknown
LIST dataset	Многоязычный	525,870 надписей на различных языках ⁴⁷	Unknown
Nuremberg Letterbooks	Многоязычный	50,980 страниц переписки с XVI века ⁵²	Open Access (Zenodo)
EPARCHOS	Древнегреческий	120 страниц рукописей, 9285 строк текста ⁴⁹	Unknown
Zenodo	Различные	Открытый репозиторий для научных данных, включая исторические документы ⁵²	Open Access
CLARIN ERIC	Различные	Доступ к цифровым языковым ресурсам, включая исторические тексты ⁷⁴	Access by membership

Важно отметить, что поддержка глаголицы остается менее развитой по сравнению с кириллицей. Хотя существуют проекты, такие как «Рукописи хорватского глаголичества», и даже специализированные модели для ее

распознавания [87](#) [88](#), количество доступных готовых моделей и датасетов значительно меньше. Это является одной из наиболее сложных задач для будущей разработки.

В заключение, хотя дефицит данных является серьезным препятствием, для славянских языков существуют конкретные и ценные наборы данных, которые можно использовать для обучения и дообучения моделей. Доступ к этим ресурсам является жизненно важным условием для создания качественного и точного приложения для распознавания исторических славянских текстов.

Сравнительный анализ производительности и применимости **OCR**-решений

Выбор оптимального инструмента для распознавания исторических славянских текстов требует не только анализа их функциональных возможностей, но и сравнительной оценки их производительности, особенно в контексте специфических вызовов, связанных с этими языками. На основе имеющихся данных можно составить представление о том, какие подходы лучше подходят для различных типов задач: работа с печатными текстами, распознавание рукописей с регулярным почерком и обработка сложных, вариативных рукописных источников.

Для печатных изданий, особенно если они выполнены в стандартном шрифте, Tesseract OCR может обеспечить приемлемое качество распознавания после дообучения на специализированных наборах данных, таких как `russian-old-orthography-ocr` [69](#). Его преимущество заключается в легкости интеграции, хорошей производительности на CPU и широкой поддержке. Однако его стандартные модели не предназначены для работы с исторической орфографией, поэтому без дообучения они будут давать много ошибок при попытке распознать текст до 1918 года [24](#). Tesseract также может работать как часть более сложных конвейеров, где он используется для первоначального извлечения текста, который затем может быть уточнен другими методами.

При переходе к рукописям ситуация усложняется. Здесь начинают проявлять себя преимущества специализированных HTR-платформ. Transkribus, с его передовыми моделями на основе трансформеров (TrOCR), демонстрирует

высокую производительность, особенно на хорошо читаемых рукописях [67](#) [80](#) . Наличие готовых, обученных на реальных манускриптах моделей для церковнославянского и старорусского языков является его ключевым преимуществом [16](#) [44](#) . Использование Transkribus позволяет получить высокое качество распознавания без необходимости глубокого погружения в детали машинного обучения. Однако платформа имеет свою специфику: она в первую очередь является веб-сервисом, и для полной свободы в разработке локального приложения может потребоваться использование ее API или интеграция с Kraken, который поддерживает те же форматы моделей [94](#) .

Kraken занимает промежуточное положение, предлагая мощный, полностью обучаемый инструмент, который можно развернуть локально. Его способность к обучаемому анализу компоновки страниц делает его особенно ценным для документов со сложной структурой, где строки могут быть наклонены, иметь разную длину или располагаться не по горизонтали [70](#) . Это свойство делает Kraken более надежным, чем Tesseract, при работе с плохо сканированными или физически поврежденными рукописями. Kraken хорошо зарекомендовал себя в академических проектах и является отличным выбором для разработчиков, которым нужна гибкость для дообучения модели под конкретный рукописный фонд [70](#) [71](#) .

Сравнительные исследования, такие как те, что проводились с участием PyLaia, HTR+ и IDA, показывают, что современные HTR-движки значительно превосходят традиционные OCR-системы на задачах распознавания рукописей [56](#) [57](#) . Эти работы подчеркивают важность выбора правильной архитектуры модели (преимущественно основанной на трансформерах) и наличия достаточного количества качественных обучающих данных. Интересно, что Tesseract, несмотря на свою специализацию на печатных текстах, может показывать лучшие результаты на данных из другой области, что говорит о необходимости тщательного тестирования и выбора модели под конкретный тип задачи [67](#) .

Что касается поддержки различных языков и алфавитов, то здесь наблюдается явный разрыв. Для кириллицы, особенно для церковнославянского и старорусского языков, доступно наибольшее количество моделей и датасетов. Существуют как общие модели, так и специализированные для разных периодов и почерков [41](#) [44](#) [45](#) . Поддержка глаголицы значительно слабее. Хотя существуют отдельные проекты и даже модели, ориентированные на нее, их количество и распространенность намного ниже, чем для кириллицы [87](#) [88](#) . Это

является самым большим ограничением текущего поколения НТТ-технологий для славянских языков.

В таблице ниже представлено сводное сравнение основных подходов.

Подход	Преимущества	Недостатки	Лучше всего подходит для
Tesseract (дообученный)	Легкость интеграции, производительность на CPU, большой функционал	Требуется дообучение для исторической орфографии, хуже справляется с рукописями	Печатные тексты до 1918 г., как базовый/резервный движок
Kraken	Полная обучаемость (компоновка + распознавание), локальное развертывание, гибкость	Требуется больше технических знаний для настройки, чем Transkribus	Рукописи с нестандартной компоновкой, дообучение под специфический фонд
Transkribus (с TrOCR)	Высочайшая точность, готовые модели для многих языков, удобный интерфейс	Зависимость от облачной платформы, коммерческая модель (хотя модели могут быть открытыми)	Высокоточные распознавания на хорошо читаемых рукописях, быстрый старт
Прочие модели (LightOnOCR и др.)	Перспективность, основаны на передовой трансформерной архитектуре	Меньший опыт применения, меньшее количество доступных моделей	Сложные случаи распознавания, когда стандартные модели не справляются

Исходя из этого анализа, для создания универсального приложения, которое должно быть как точным, так и гибким, оптимальной стратегией будет использование многоуровневой архитектуры. Приложение должно предлагать пользователю выбор между разными движками: Tesseract для быстрой обработки печатных текстов, Kraken для более сложных рукописей, где может потребоваться дообучение, и возможность использовать самые передовые модели из Transkribus для достижения максимального качества на ключевых проектах. Особое внимание следует уделить развитию поддержки глаголицы, так как это одно из самых слабых мест в текущей экосистеме.

Практическая реализация: Архитектурные подходы и стратегия интеграции

На основе всестороннего анализа существующих инструментов, научных публикаций и наборов данных можно сформулировать четкие практические рекомендации по созданию локального GUI-приложения для распознавания исторических славянских текстов. Успех проекта зависит не столько от выбора одного "лучшего" инструмента, сколько от разработки гибкой и многоуровневой

архитектуры, которая сможет адаптироваться к разнообразию исходных материалов и предоставлять пользователю максимальный контроль над процессом.

Первым и ключевым архитектурным решением является внедрение многоуровневой системы распознавания. Приложение не должно полагаться на один движок. Вместо этого следует реализовать конвейер, включающий несколько этапов: 1. Уровень 1 (Базовый): Tesseract OCR. Этот уровень должен использоваться по умолчанию для обработки печатных текстов и как "резервная" система для участков рукописей, которые не удалось распознать на следующих уровнях. Обязательным элементом является механизм дообучения Tesseract на специализированном датасете, таком как `russian-old-orthography-ocr` [69](#), что позволит ему корректно работать с исторической орфографией. 2. Уровень 2 (Основной): Kraken. Этот движок должен стать основным инструментом для обработки рукописных текстов. Его ключевые преимущества — полная обучаемость и возможность локального развертывания — делают его идеальным выбором [70](#). Приложение должно предоставлять пользователю инструменты для дообучения модели Kraken на собственных наборах данных, что позволит адаптировать ее к специфическим рукописным фрагментам. 3. Уровень 3 (Продвинутый): Интеграция моделей из Transkribus. Для достижения максимального качества распознавания приложение должно поддерживать скачивание и использование передовых трансформерных моделей (TrOCR, LightOnOCR) [21](#) [80](#). Это может быть реализовано через API Transkribus или путем прямой загрузки моделей, совместимых с Kraken. Этот уровень предназначен для сложных случаев, где требуется высочайшая точность.

Вторым важным аспектом является разработка мощного и настраиваемого конвейера предобработки изображений. Качество распознавания сильно зависит от качества входного скана, а исторические документы часто имеют множество артефактов [53](#). Приложение должно включать в себя набор операций предобработки, которые можно включать и выключать, а также выбирать режим их выполнения (например, "быстро", "баланс", "высокое качество"). Эти операции должны включать преобразование в оттенки серого, нормализацию DPI, поворот для устранения перекоса, удаление шума, повышение контраста с помощью CLAHE, адаптивную бинаризацию и обрезку полей [70](#). Важно, чтобы пользователь мог видеть результат каждой операции в реальном времени на примере текущей страницы, прежде чем запускать основной процесс распознавания.

Третьим обязательным компонентом является пользовательский интерфейс, который должен быть максимально простым и интуитивно понятным для "обычных пользователей", не обладающих глубокими техническими знаниями ⁶⁵. Главное окно должно быть разделено на две части: слева — просмотр исходного изображения с возможностью масштабирования и навигации по страницам, справа — редактируемое текстовое поле с распознанным текстом ⁷⁰. Пользователю должны быть доступны кнопки "Открыть файл", "Распознать", "Экспортировать" и панель настроек. Настройки должны быть разделены на "Основные" (выбор языка, режим предобработки) и "Дополнительные" (детальные параметры OCR, пути к пользовательским моделям). Вся фоновая работа, включая предобработку, OCR и экспорт, должна выполняться в отдельном потоке (например, с использованием QThread в PyQt/PySide), чтобы главное окно приложения не зависало ⁷⁰.

Стратегия работы с данными должна быть двунаправленной. С одной стороны, приложение должно поставляться с набором базовых моделей (например, стандартные `tessdata` для Tesseract и общие модели для Kraken). С другой стороны, оно должно содержать каталог или встроенную ссылку на внешние ресурсы, где пользователь может найти и скачать дополнительные специализированные модели и датасеты, такие как `Combined_Full_VKS_2` для церковнославянского языка ⁷ или модели для глаголицы ⁸⁷. Предоставление кнопки "Загрузить модель" может значительно упростить этот процесс для пользователя.

Наконец, необходимо уделить особое внимание обработке ошибок и пользовательскому опыту. Если Tesseract не установлен или не найден языковой пакет, приложение не должно аварийно завершаться. Вместо этого оно должно показывать понятное информационное окно с пошаговой инструкцией, где пользователь может найти все необходимые файлы и руководства по установке ^{65 66}. Все технические термины (CER, LSTM, Transformer) должны быть скрыты от обычного пользователя. Диалоги с ошибками должны быть дружелюбными и давать конкретные советы по их устранению. Обязательным элементом является редактор распознанного текста, позволяющий пользователю вносить исправления вручную. Ни одна автоматическая система пока не достигла 100% точности, и возможность ручной проверки и коррекции является критически важной для получения качественного результата.

В качестве итоговой дорожной карты для разработки можно предложить следующий план действий: 1. Создать базовую структуру приложения с GUI на

PyQt/PySide. 2. Реализовать основной функционал: открытие файлов (изображений, PDF), отображение изображений и текста. 3. Интегрировать Tesseract OCR с механизмом дообучения. 4. Интегрировать Kraken OCR. 5. Реализовать мощный конвейер предобработки изображений. 6. Создать панель настроек и систему управления моделями. 7. Реализовать функционал экспорта в TXT, DOCX и PDF форматы. 8. Тщательно протестировать приложение на разнообразных наборах данных (печать, рукописи, разное качество сканов). 9. Собрать всю документацию и инструкции в README.md, включая ссылки на датасеты и модели.

Следование этому комплексному подходу позволит создать не просто очередную OCR-программу, а мощный и гибкий инструмент для цифровизации культурного наследия, который будет полезен как профессиональным историкам, так и любителям семейной истории.

Справка

1. Proceedings of LT4HALA 2024: The Third Workshop on ... <https://aclanthology.org/2024.lt4hala-1.pdf>
2. Generic HTR model for Old Cyrillic uncial and semi- ... <https://zenodo.org/records/7755483>
3. old russian / church slavonic glyphs? · Issue #24 · tesseract ... https://github.com/tesseract-ocr/tessdata_best/issues/24
4. (PDF) Integrating Field Models into Transkribus-based ... https://www.researchgate.net/publication/412059664_Integrating_Field_Models_into_Transkribus-based_HTR_Pipelines_for_Early_East_Slavic_Cyrillic_Manuscripts
5. Old Slavonic and the Slavonic Alphabets <https://rezansky.com/old-slavonic-and-the-slavonic-alphabets/>
6. Early Cyrillic alphabet https://en.wikipedia.org/wiki/Early_Cyrillic_alphabet
7. Combined_Full_VKS_2 | Church Slavic Text Recognition ... <https://www.transkribus.org/models/russian-church-slavonic-1>
8. On the appearance and development of Cyrillic letterforms <https://typejournal.ru/en/articles/Cyrillic-Letterforms-Development>

9. Old Church Slavonic Writing: Glagolitic vs. Cyrillic <https://www.languagesoftheworld.info/writing-or-spelling/old-church-slavonic-writing-glagolitic-vs-cyrillic.html>
10. Glagolitic Alphabet: Old Church Slavonic Script Explained <https://www.remitly.com/blog/education/glagolitic-alphabet/>
11. Evaluating LLMs for Historical Document OCR <https://arxiv.org/html/2510.06743v1>
12. Churro: Making History Readable with an Open-Weight ... <https://arxiv.org/html/2509.19768v1>
13. arXiv:2112.14153v1 [cs.CL] 28 Dec 2021 <https://arxiv.org/pdf/2112.14153>
14. Named Entity Recognition and Classification in Historical ... <https://dl.acm.org/doi/full/10.1145/3604931>
15. Named Entity Recognition and Classification in Historical ... <https://dl.acm.org/doi/pdf/10.1145/3604931>
16. Inviting AI into the Archives: The Reception of Handwritten ... <https://www.transcript-open.de/doi/10.14361/9783839455845-008?html>
17. A survey of historical document image datasets <https://link.springer.com/article/10.1007/s10032-022-00405-8>
18. Instruction Finetuning to Attribute Language Stage, Dialect, ... <https://aclanthology.org/2025.ranlp-1.76.pdf>
19. Digitising (Romanian) Cyrillic using Transkribus https://www.academia.edu/89646340/Digitising_Romanian_Cyrillic_using_Transkribus_new_perspectives
20. 5 AI models for transcribing old Russian handwriting and ... <https://www.transkribus.org/blog/5-ai-models-for-transcribing-old-russian-handwriting-and-printed-russian-texts>
21. wjbmattngly/LightOnOCR-2-1B-old-church-slavonic-line <https://huggingface.co/wjbmattngly/LightOnOCR-2-1B-old-church-slavonic-line>
22. 5 AI Models For Transcribing Old Russian Handwriting And ... <https://medium.com/transkribus/5-ai-models-for-transcribing-old-russian-handwriting-and-printed-russian-texts-361ee90a6bfd>
23. Ground Truth transcriptions for training OCR of historical ... <https://bl.iro.bl.uk/work/6694175f-e489-4f9e-bcdd-3058f5e0aa23>
24. russian-old? https://groups.google.com/g/tesseract-ocr/c/iVbKc2IA1_Q
25. wjbmattngly/old-church-slavonic-dots-ocr <https://huggingface.co/wjbmattngly/old-church-slavonic-dots-ocr>
26. Review of Modern Handwritten Text Recognition Methods ... <https://www.researchgate.net/publication/>

408432547_Review_of_Modern_Handwritten_Text_Recognition_Methods_Applicable_for_Old_Church_Slavonic_Manuscripts_Processing

27. Handwritten Text Recognition: A Survey <https://arxiv.org/html/2502.08417v1>
28. Ancient Script Image Recognition and Processing: A Review <https://arxiv.org/html/2506.19208v1>
29. (PDF) Comparative Analysis of Handwritten Text ... https://www.researchgate.net/publication/399370286_Comparative_Analysis_of_Handwritten_Text_Recognition_Across_Cyrillic-Using_Countries
30. Improving OCR for Historical Texts of Multiple Languages <https://arxiv.org/html/2508.10356v1>
31. Handwritten Text Recognition of Historical Manuscripts ... <https://arxiv.org/html/2508.11499v1>
32. Historical Text Line Segmentation Using Deep Learning ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC10971631/>
33. Comparative Analysis of Handwritten Text Recognition ... https://ideas.repec.org/h/spr/lnichp/978-3-032-06725-8_27.html
34. A Transformer Based Handwriting Recognition System ... <https://arxiv.org/html/2506.20255v1>
35. Handwritten Text Recognition for Historical Documents ... https://hal.science/hal-04716654v2/file/HTR_transformers_LLM_GAN.pdf
36. Secondary Sources - Old Church Slavic and ... <https://guides.loc.gov/old-church-slavonic-and-church-slavic/secondary-sources>
37. OLD SLAVONIC MANUSCRIPTS - Biblical-data.org https://www.biblical-data.org/OCS/Slavonic_samples.htm
38. External Resources - Old Church Slavic and ... <https://guides.loc.gov/old-church-slavonic-and-church-slavic/external-resources>
39. Resource Center for Medieval Slavic Studies - The Ohio State ... <https://rcmss.osu.edu/resources>
40. Microfilm - Old Church Slavic and ... <https://guides.loc.gov/old-church-slavonic-and-church-slavic/microfilm>
41. Slavonic Digital Projects and Resources <https://www.obshtezhitie.net/Slav.xhtml>
42. Category:Church Slavonic manuscripts https://commons.wikimedia.org/wiki/Category:Church_Slavonic_manuscripts
43. Medieval Slavic Manuscript Studies Research Papers https://www.academia.edu/Documents/in/Medieval_Slavic_Manuscript_Studies

44. taiga75/ru-trocr-1700s <https://huggingface.co/taiga75/ru-trocr-1700s>
45. cyrillic-trocr/trocr-handwritten-cyrillic <https://huggingface.co/cyrillic-trocr/trocr-handwritten-cyrillic>
46. Is it possible to add few pre-1918 Russian characters ... https://github.com/tesseract-ocr/langdata_lstm/issues/3
47. LIST <https://zenodo.org/records/10473706>
48. MPS Data set with images of medieval charters for ... <https://zenodo.org/records/1194357>
49. Historical Greek handwritten document dataset - EPARCHOS <https://zenodo.org/records/4095301>
50. iForal: Automated Handwritten Text Transcription for Historical ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC11856379/>
51. A Text Recognition Dataset from Sahidic Coptic Ancient ... <https://arxiv.org/html/2606.15987v1>
52. Nuremberg Letterbooks: A Multi-Transcriptional Dataset of ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC12085573/>
53. FP-THD: Full page transcription of historical documents <https://arxiv.org/html/2601.17040v1>
54. Can Multi-Modal LLMs Transcribe Historic Documents? <https://content.fromthepage.com/can-multi-modal-llms-transcribe-historic-documents/>
55. Handwritten Paleographic Greek Text Recognition <https://aclanthology.org/2022.lrec-1.708.pdf>
56. Assessing advanced handwritten text recognition engines for ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC12202554/>
57. Assessing advanced handwritten text recognition engines ... https://www.researchgate.net/publication/391669422_Assessing_advanced_handwritten_text_recognition_engines_for_digitizing_historical_documents
58. Online Tools for Handwritten Text Recognition: A ... <https://blog.stoa.org/archives/4308>
59. (PDF) Comparison of models for recognition of Old Slavic ... https://www.researchgate.net/publication/256375180_Comparison_of_models_for_recognition_of_Old_Slavic_Characters
60. Generic Church Slavonic Handwriting 3 <https://www.transkribus.org/models/generic-church-slavonic-handwriting-3>
61. The Digital Revolution in Slavic Manuscript Studies: HTR ... <https://oaj.fupress.net/index.php/ss/article/view/17690>

62. ArchXAI project develops AI-powered handwritten text ... <https://centralbaltic.eu/project-news/archxai-project-develops-ai-powered-handwritten-text-recognition-for-19th-and-20th-century-russian/>
63. HANDWRITTEN TEXT RECOGNITION FOR CROATIAN ... <https://www.semanticscholar.org/paper/HANDWRITTEN-TEXT-RECOGNITION-FOR-CROATIAN-Rabus/f37d6b9fde3716235a84c0253671b287cd7e7cc4>
64. achimrabus/polyscriptor: Multi-engine ATR for multiple ... <https://github.com/achimrabus/polyscriptor>
65. tesseract-ocr/tessdata: Trained models with ... <https://github.com/tesseract-ocr/tessdata>
66. tessdata_fast – Fast integer versions of trained models https://github.com/tesseract-ocr/tessdata_fast
67. Daily Papers <https://huggingface.co/papers?q=Transkribus>
68. 5 AI Models For Transcribing Old Russian Handwriting ... - Blog <https://blog.transkribus.org/en/5-ai-models-for-transcribing-old-russian-handwriting-and-printed-russian-texts>
69. nevmenandr/russian-old-orthography-ocr · Datasets at ... <https://huggingface.co/datasets/nevmenandr/russian-old-orthography-ocr>
70. mittagessen/kraken: OCR engine for all the languages <https://github.com/mittagessen/kraken>
71. AjaxMultiCommentary/OCR-kraken-models <https://github.com/AjaxMultiCommentary/OCR-kraken-models>
72. translating connectors: the case of old church slavonic https://www.researchgate.net/publication/349111169_TRANSLATING_CONNECTORS_THE_CASE_OF_OLD_CHURCH_SLAVONIC
73. old-church-slavonic (PF) <https://www.evertype.com/alphabets/old-church-slavonic.pdf>
74. Data | CLARIN ERIC - Common Language Resources and ... <https://www.clarin.eu/content/data>
75. CLARIN and DARIAH - Digital Humanities Course Registry <https://dhcr.clarin-dariah.eu/info>
76. The application of HTR and LLM tools to Church Slavonic ... https://www.academia.edu/170519002/Textual_Networks_of_St_Wenceslas_The_application_of_HTR_and_LLM_tools_to_Church_Slavonic_Hagiographical_Sources

77. Catalog using Cyrillic scripts https://help.oclc.org/Metadata_Services/Connexion/Connexion_client/Non-Latin_cataloging/Input_methods_for_languages_that_use_non-Latin_scripts/Catalog_using_Cyrillic_scripts
78. Proposal to Change Annotations on Some Cyrillic Characters <https://www.unicode.org/L2/L2015/15014-cyrillic-annot.pdf>
79. Recognition of Church Slavonic Texts Using Machine ... <https://ouci.dntb.gov.ua/en/works/4yX6YXx7/>
80. arXiv:2109.10282v5 [cs.CL] 6 Sep 2022 <https://arxiv.org/pdf/2109.10282>
81. Synthetized Multilanguage OCR Using CRNN and SVTR ... <https://www.mdpi.com/2076-3417/13/7/4419>
82. Hungarian Handwritten Text Recognition <https://f1000research.com/articles/15-181/pdf>
83. A dataset for the DIACHronic analysis of Church Slavonic <https://aclanthology.org/2025.bsnlp-1.12/>
84. Slavic Cataloging Manual - Transcribing Church Slavic <https://sites.google.com/site/seesscm/transcribing-church-slavic>
85. Old Church Slavonic – Text sample - TIB AV-Portal <https://av.tib.eu/media/49453>
86. TOCST The Transmission of Old Church Slavonic Texts <https://pric.unive.it/projects/tocst/home>
87. [PDF] HANDWRITTEN TEXT RECOGNITION FOR CROATIAN GLAGOLITIC <https://hrcak.srce.hr/file/391286>
88. Handwritten Glagolitic | Church Slavic, Croatian Text Recognition ... <https://www.transkribus.org/models/glagolitic-handwritten-14th-and-15th-century>
89. Old Church Slavonic <https://spw.uni-goettingen.de/projects/aig/doc/CHU-INT-001.pdf>
90. Slavic Cyrillic and Glagolitic Manuscripts Research Papers https://www.academia.edu/Documents/in/Slavic_Cyrillic_and_Glagolitic_Manuscripts
91. Old Church Slavonic alphabet and language <https://www.pinterest.com/pin/discover-the-beauty-of-old-church-slavonic--2533343534475883/>
92. Old Church Slavonic Grammar <https://theswissbay.ch/pdf/Books/Linguistics/Mega%20linguistics%20pack/Indo-European/Balto-Slavic/Old%20Church%20Slavonic%20Grammar%20%28Lunt%29.pdf>
93. Semi-automatic pipeline for constructing HTR corpora from ... <https://ceur-ws.org/Vol-4159/paper12.pdf>
94. ARletta. Open-Source Handwritten Text Recognition Models ... <https://openhumanitiesdata.metajnl.com/articles/225>